Avaliação numérica retrospectiva do DengueSphere: 13 anos de casos de dengue no Recife (2013–2025)

1 Desenho do estudo numérico

Como o DengueSphere ainda não foi adotado na rotina da vigilância municipal, a avaliação foi conduzida como um *estudo numérico retrospectivo*: o software foi reexecutado sobre o histórico de notificações e suas saídas foram confrontadas com o que efetivamente ocorreu nas semanas seguintes. Todas as clusterizações usam as funções do próprio serviço de processamento do DengueSphere (`executar_clusterizacao` e `stability_analysis`, DBSCAN com métrica haversine), sem reimplementação.

Dados. Foram utilizadas as notificações de dengue do SINAN publicadas no portal de dados abertos do Recife (licença ODbL) para 2013–2025. Os 13 arquivos anuais apresentam dois esquemas de nomes de colunas, três formatos de CSV e três codificações de caracteres, padronizados em uma única base. Incluíram-se residentes no Recife (IBGE 261160) com classificação final confirmada — códigos 1 a 4 da classificação vigente até 2014 (dengue clássico, dengue com complicações, febre hemorrágica, síndrome do choque) e 10 a 12 da classificação revisada (dengue, dengue com sinais de alarme, dengue grave). Descartados e inconclusivos foram excluídos da análise principal. A data de referência é a do início dos sintomas (ou da notificação, quando ausente).

Geocodificação. Os arquivos públicos não contêm coordenadas. Para geocodificar os 69.681 registros não descartados (29.043 pares únicos logradouro–bairro) sem violar os limites de uso do serviço Nominatim, a cascata de geocodificação do DengueSphere (logradouro → bairro → não encontrado) foi reproduzida sobre uma base local do OpenStreetMap: 18.739 trechos de logradouros nomeados recortados pelos 94 polígonos de bairros (219,3 km^2). Os nomes foram normalizados (abreviações, ordinais, números por extenso, caracteres corrompidos) e casados por similaridade textual (*token sort ratio* ≥ 85). A concordância com o geocodificador original foi medida na amostra de 2021 já processada pelo DengueSphere.

População. Os denominadores vêm do Censo Demográfico 2022 do IBGE, usando a malha de setores censitários com atributos (2.836 setores, 1.488.924 habitantes no Recife). A população de cada setor foi distribuída entre as células de uma grade regular de 100 m na proporção da área de interseção (ponderação areal). A soma por bairro reproduziu os totais publicados pelo IBGE com correlação de 0,9995 e diferença absoluta mediana de 1,9%. A mesma população de 2022 foi usada em todos os anos; a população do município variou pouco no período (cerca de -3% entre os Censos de 2010 e 2022). A Figura 1 ilustra o procedimento.

Janelas de análise. A unidade de avaliação é a *janela* de 4 semanas epidemiológicas de casos geocodificados no nível de logradouro, que reproduz o uso pretendido do software (seleção de semanas recentes e clusterização). As janelas foram estratificadas pelo nível de incidência: baixa (< 100 casos), média (100–400) e alta (> 400).

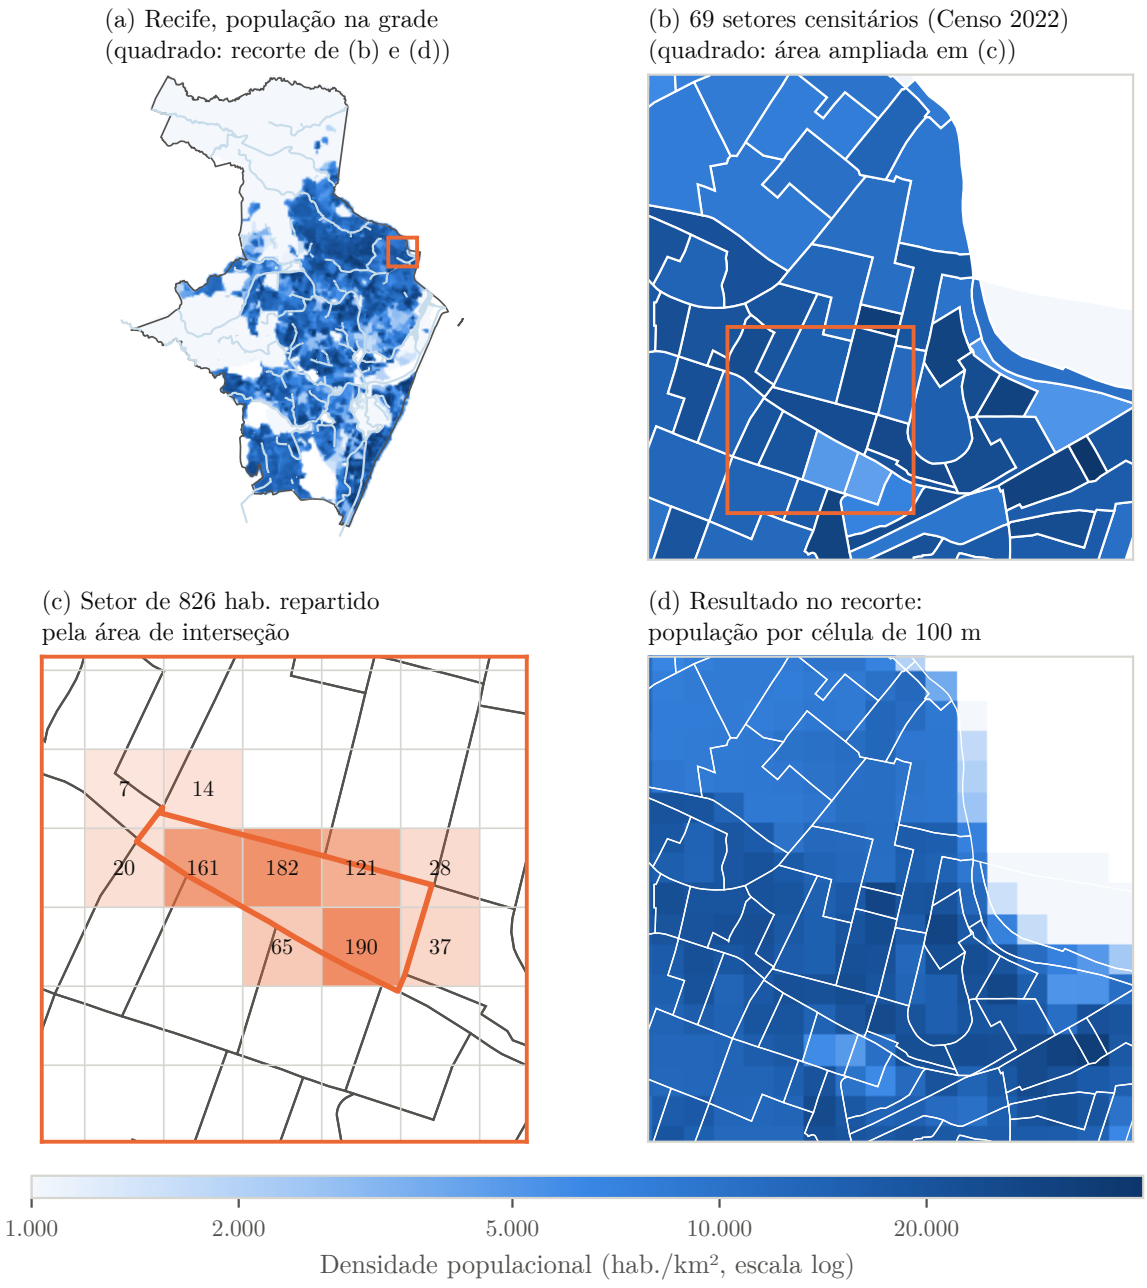


Figura 1: Distribuição da população do Censo 2022 na grade de 100 m por ponderação areal. (a) Resultado para todo o município. (b) Setores censitários de um recorte de 1,6 km na zona norte, coloridos pela densidade populacional. (c) Ampliação de um setor de 826 habitantes: cada célula recebe a fração da população proporcional à área do setor que ela cobre (números: habitantes atribuídos à célula; soma = 826). (d) População por célula no mesmo recorte, na mesma escala de cores de (b).

Métricas. (i) *Sensibilidade* aos parâmetros: número de clusters, proporção de ruído e silhueta na grade $\varepsilon \in \{0{,}1;\ 0{,}2;\ 0{,}3;\ 0{,}5;\ 0{,}75;\ 1{,}0\}$ km × `min_samples` $\in \{3, 5, 10, 15, 20\}$. (ii) *Estabilidade*: índice de Rand ajustado (ARI) entre a solução de referência e soluções com $\varepsilon \pm 10\%$, `min_samples` ± 1 e subamostras de 90% dos casos. (iii) *Validação prospectiva*: a cada semana t, o DBSCAN é aplicado às semanas $t-3, \ldots, t$; a área sinalizada é o conjunto de células de 100 m a até ε de um caso pertencente a algum cluster. Mede-se a captura (fração dos casos das semanas $t+1, \ldots, t+4$ dentro da área) e o *Predictive Accuracy Index*,

$$\mathrm{PAI} = \frac{\text{casos futuros na área} \,/\, \text{casos futuros}}{\text{área sinalizada} \,/\, \text{área do município}}, \tag{1}$$

em que PAI = 1 equivale a uma escolha aleatória de áreas. Como áreas densamente povoadas tendem a ter mais casos apenas por terem mais moradores, calculou-se também o PAI populacional,

$$\mathrm{PAI}_{\mathrm{pop}} = \frac{\text{casos futuros na área} \,/\, \text{casos futuros}}{\text{população na área} \,/\, \text{população do município}}, \tag{2}$$

que vale 1 quando a área sinalizada tem o mesmo risco por habitante que a média da cidade. O DBSCAN é comparado com quatro referências: estimativa de densidade kernel (KDE) com a mesma área; ranking de bairros por incidência (casos por habitante) na janela; as células mais populosas com a mesma área, sem nenhuma informação sobre casos; e um *buffer* de todos os casos da janela sem clusterização. Os parâmetros foram escolhidos em 2013–2019 (treino) e avaliados em 2020–2025 (teste), com comparação pareada por janela pelo teste de postos sinalizados de Wilcoxon. (iv) *Persistência interanual*: correlação de Spearman entre anos dos casos por célula de 500 m e da incidência por bairro. (v) *Desempenho computacional*.

2 Resultados

2.1 Base de dados e geocodificação

Entre 2013 e 2025 foram registradas 110.468 notificações de dengue de residentes no Recife, das quais 63.347 (57,3%) foram confirmadas (Tabela 1). A série é dominada pela epidemia de 2015–2016, que concentra 35.659 confirmações (56,3% do período), com pico de 1.573 casos na semana epidemiológica 14 de 2015 (Figura 2). Seguem-se 2021 (7.435 casos) e 2025 (5.066). A incidência média foi de 327 casos por 100 mil habitantes por ano, variando de 64 (2017) a 1.583 por 100 mil (2015). O arquivo de 2014 termina em julho, o que produz uma lacuna de cinco meses na série e subestima a incidência daquele ano.

A geocodificação local posicionou 82,4% dos casos confirmados no nível de logradouro, 17,1% no ponto representativo do bairro e deixou 0,5% sem localização. A proporção no nível de rua variou de 80,8% (2015) a 87,8% (2024), com tendência de melhora nos anos recentes (Figura 3).

Na amostra de 2021 processada pelo próprio DengueSphere (Tabela 2), nos 809 casos em que ambos os métodos encontraram o logradouro, a distância mediana entre as coordenadas foi de 56 m (percentil 90: 291 m), e 94,9% ficaram a até 500 m — distância inferior ao menor ε útil identificado adiante. A base local também resolveu no nível de rua 148 casos que o Nominatim só localizou pelo bairro. No sentido inverso, os 47 casos marcados pelo Nominatim como "rua sem bairro" e que a base local situou no bairro informado ficaram a uma mediana de 5,5–6,1 km, provavelmente por logradouros homônimos em outros pontos da cidade escolhidos erroneamente pelo serviço externo.

2.2 Padrões espaciais

Os mapas de calor anuais da densidade de casos (Figura 4) mostram concentração recorrente na zona norte (Água Fria, Casa Amarela, Nova Descoberta) e no extremo sudoeste (Cohab, Ibura),



Figura 2: Casos confirmados de dengue por semana epidemiológica, Recife, 2013–2025. A faixa cinza indica o período sem dados no arquivo de 2014.

Tabela 1: Notificações, casos confirmados, incidência e precisão da geocodificação por ano epidemiológico, Recife, 2013–2025.

Ano	Notificados	Confirmados	Incid./100 mil	Rua (%)	Bairro (%)	Não enc. (%)	Pico/sem.	SE do pico
2013	3.262	1.304	87,6	85,4	14,6	0,0	77	18
2014	1.159	363	24,4	85,7	14,3	0,0	24	20
2015	34.675	23.576	1.583,4	80,8	18,6	0,5	1.573	14
2016	18.505	12.083	811,5	81,6	17,3	1,0	1.144	6
2017	2.445	955	64,1	81,9	18,1	0,0	41	2
2018	2.686	1.207	81,1	81,3	18,2	0,5	53	19
2019	7.309	4.102	275,5	81,3	17,6	1,0	190	34
2020	3.619	1.544	103,7	81,0	18,5	0,5	79	30
2021	10.977	7.435	499,4	82,4	17,6	0,0	569	22
2022	2.795	1.291	86,7	83,5	16,3	0,2	55	31
2023	3.502	1.414	95,0	86,0	13,9	0,1	57	11
2024	10.483	3.007	202,0	87,8	12,0	0,2	160	10
2025	9.051	5.066	340,2	87,0	12,9	0,1	215	31
Total	110.468	63.347	327,3	82,4	17,1	0,5	–	–

Notificados: residentes no Recife com data válida (qualquer classificação). Incidência: confirmados por 100 mil habitantes (Censo 2022, 1.488.924 hab.); na linha Total, média anual. Rua: geocodificado no nível de logradouro (no bairro informado, em bairro vizinho ou único na cidade). Bairro: ponto representativo do polígono do bairro. SE: semana epidemiológica. O arquivo de 2014 contém notificações apenas até julho.

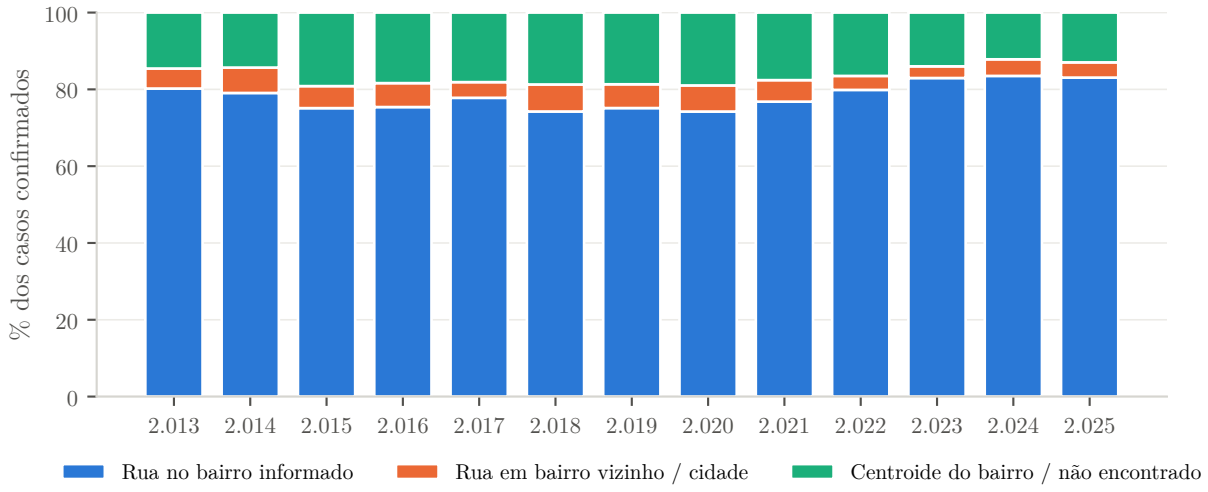


Figura 3: Nível de precisão da geocodificação por ano.

Tabela 2: Distância entre a geocodificação local (OSM) e a do DengueSphere (Nominatim) na amostra de 2021 ($n = 1.219$).

Nominatim	Local (OSM)	n	Mediana (m)	P90 (m)	≤250 m	≤500 m	≤1 km
Endereço exato	Centroide do bairro	60	298	1.103	35,0	65,0	86,7
	Rua no bairro	794	55	278	88,5	95,1	98,7
	Rua em bairro vizinho	11	158	489	63,6	90,9	100,0
Fallback bairro	Centroide do bairro	61	276	840	42,6	88,5	90,2
	Rua no bairro	148	471	1.056	25,0	52,7	87,2
	Rua em bairro vizinho	9	1.279	1.872	0,0	0,0	44,4
Fallback bairro corrigido	Centroide do bairro	9	513	1.609	0,0	33,3	88,9
	Rua no bairro	31	1.156	2.371	6,5	16,1	41,9
Rua sem bairro	Centroide do bairro	31	5.497	23.520	0,0	0,0	0,0
	Rua no bairro	16	6.138	12.549	0,0	0,0	0,0
	Rua em bairro vizinho	41	102	317	82,9	90,2	92,7

Colunas ≤: percentual de casos a até a distância indicada. Categorias com $n < 9$ omitidas.

com focos variáveis no oeste (Várzea, Iputinga) e na orla sul. Contagens absolutas, porém, refletem em parte onde mora mais gente. Ajustada pela população (Tabela 3 e Figura 5), a incidência média anual variou de 99 a 993 casos por 100 mil habitantes entre os 72 bairros com pelo menos 5 mil moradores (mediana 326). Boa Viagem, segundo bairro em número absoluto de casos (2.592), tem incidência de 164 por 100 mil e ocupa a 62ª posição; Campina do Barreto, com 1.091 casos em 8.452 habitantes, tem incidência seis vezes maior (993 por 100 mil). O mapa de risco relativo por bairro (Figura 6) confirma o padrão: nos anos epidêmicos, risco acima da média nos morros da zona norte e no sudoeste, e abaixo da média na orla e em bairros como Boa Viagem, Espinheiro e Graças (121 a 164 casos por 100 mil).

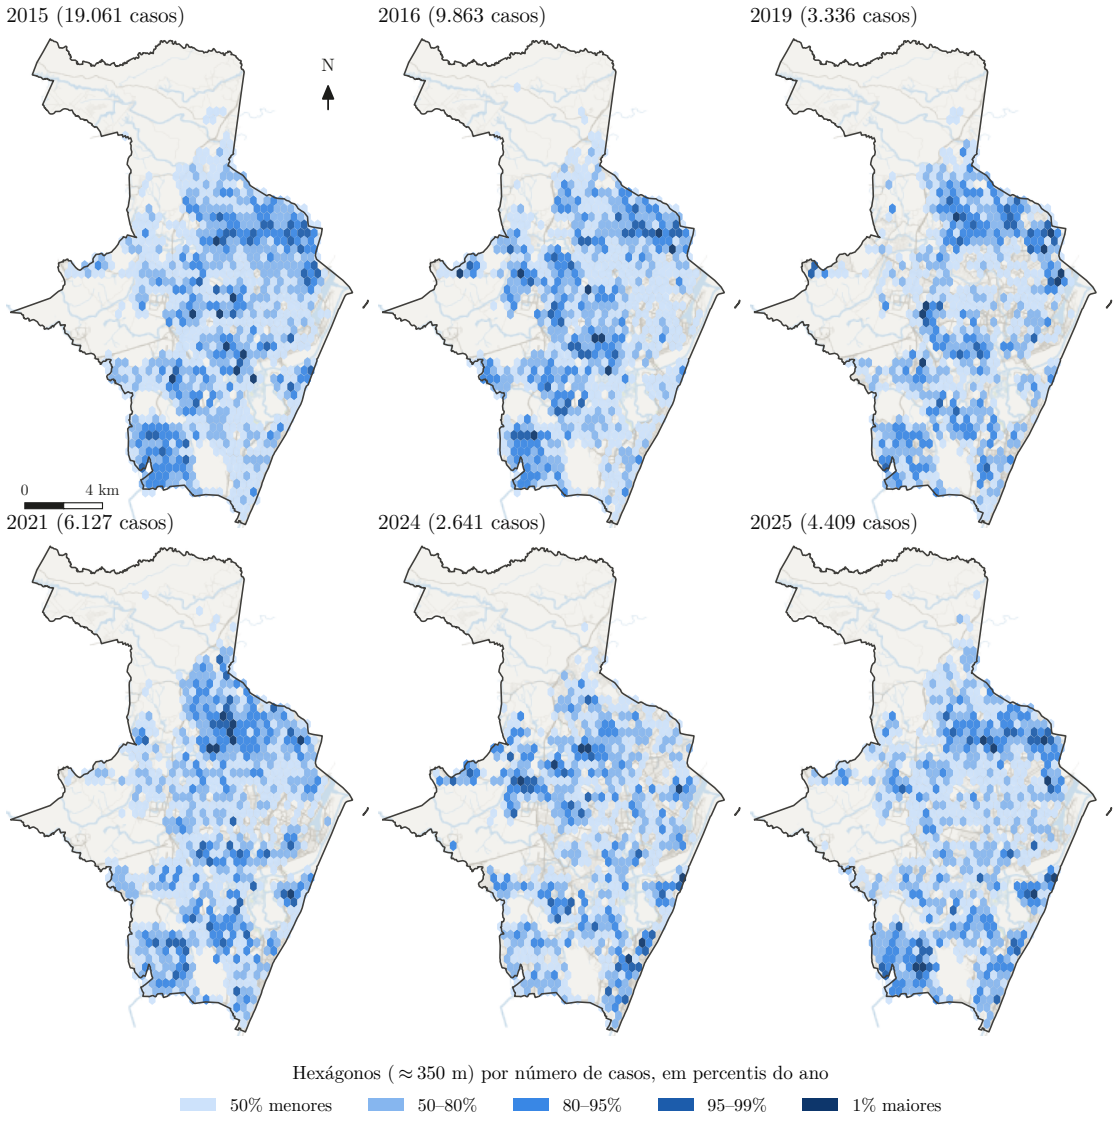


Figura 4: Mapas de calor da distribuição dos casos confirmados geocodificados no nível de logradouro nos seis anos com mais casos (os demais anos têm entre 311 e 1.251 casos geocodificados; todos os 13 anos estão na Figura 13). Cada hexágono (cerca de 350 m) é classificado pelo percentil do seu número de casos entre os hexágonos com casos no mesmo ano, o que torna os anos comparáveis apesar das diferenças de magnitude. Mapa base: OpenStreetMap (ruas, rios e mangues).

Entre anos consecutivos, a correlação de Spearman dos casos por célula de 500 m foi em média 0,52 (0,37 a 0,79; Tabela 4 e Figura 7). As células no decil superior de um ano, que ocupam cerca de 12% das células com casos, concentraram em média 26,2% dos casos do ano seguinte, pouco mais que o dobro do esperado ao acaso. Em incidência por bairro, a correlação entre anos consecutivos foi menor (média 0,35; negativa apenas entre 2014, ano incompleto, e 2015). A persistência existe,

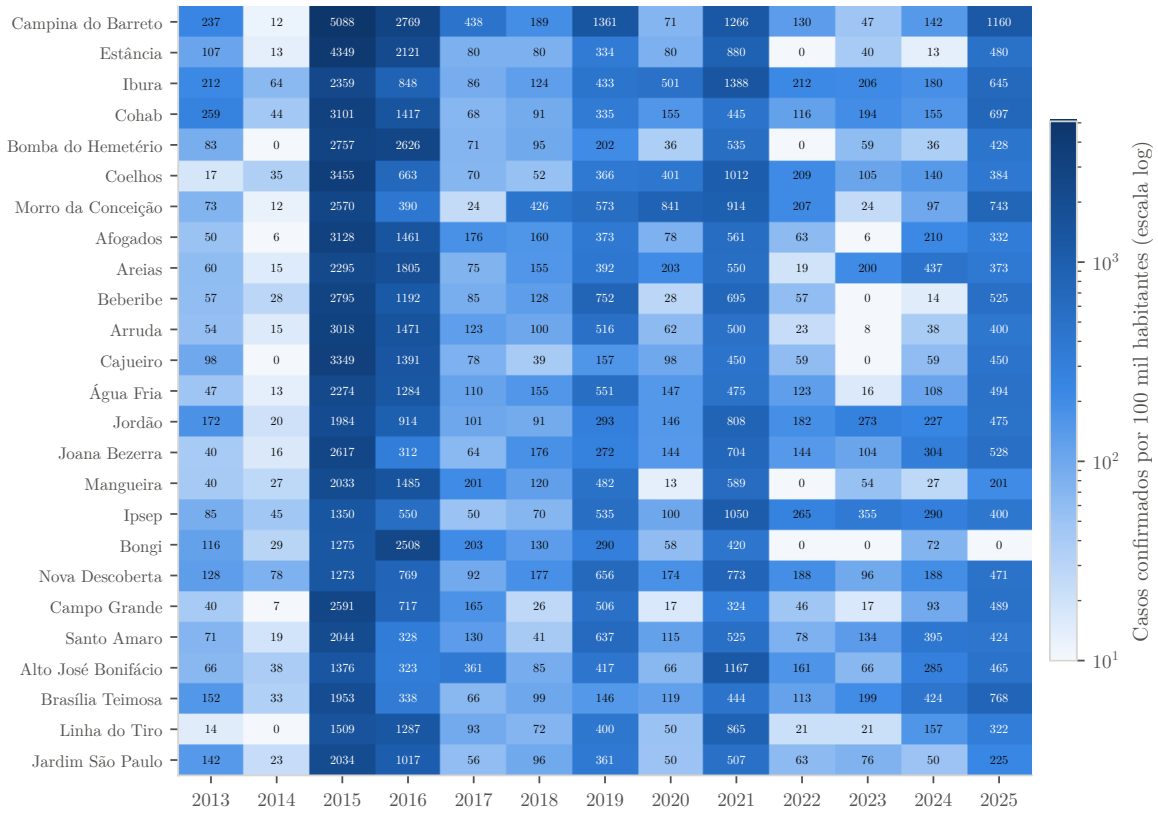


Figura 5: Mapa de calor da incidência anual de dengue (casos confirmados por 100 mil habitantes, escala logarítmica) nos 25 bairros de maior incidência média, entre os que têm pelo menos 5 mil moradores.

Tabela 3: Bairros com maior incidência média anual de dengue, 2013–2025.

	Bairro	População (2022)	Casos	Incidência média anual/100 mil
1	Campina do Barreto	8.452	1.091	992,9
2	Estância	7.496	643	659,9
3	Ibura	46.679	3.388	558,3
4	Cohab	61.408	4.345	544,3
5	Bomba do Hemetério	8.415	583	532,9
6	Coelhos	5.731	396	531,5
7	Morro da Conceição	8.209	566	530,4
8	Afogados	31.901	2.107	508,1
9	Areias	26.537	1.746	506,1
10	Beberibe	7.047	448	489,0
11	Arruda	12.988	822	486,8
12	Cajueiro	5.106	318	479,1
13	Água Fria	38.086	2.208	446,0
14	Jordão	19.808	1.126	437,3
15	Joana Bezerra	12.495	678	417,4

Casos confirmados com bairro identificado (inclui casos localizados pelo centroide). Apenas bairros com pelo menos 5.000 habitantes. População estimada por ponderação areal dos setores censitários.

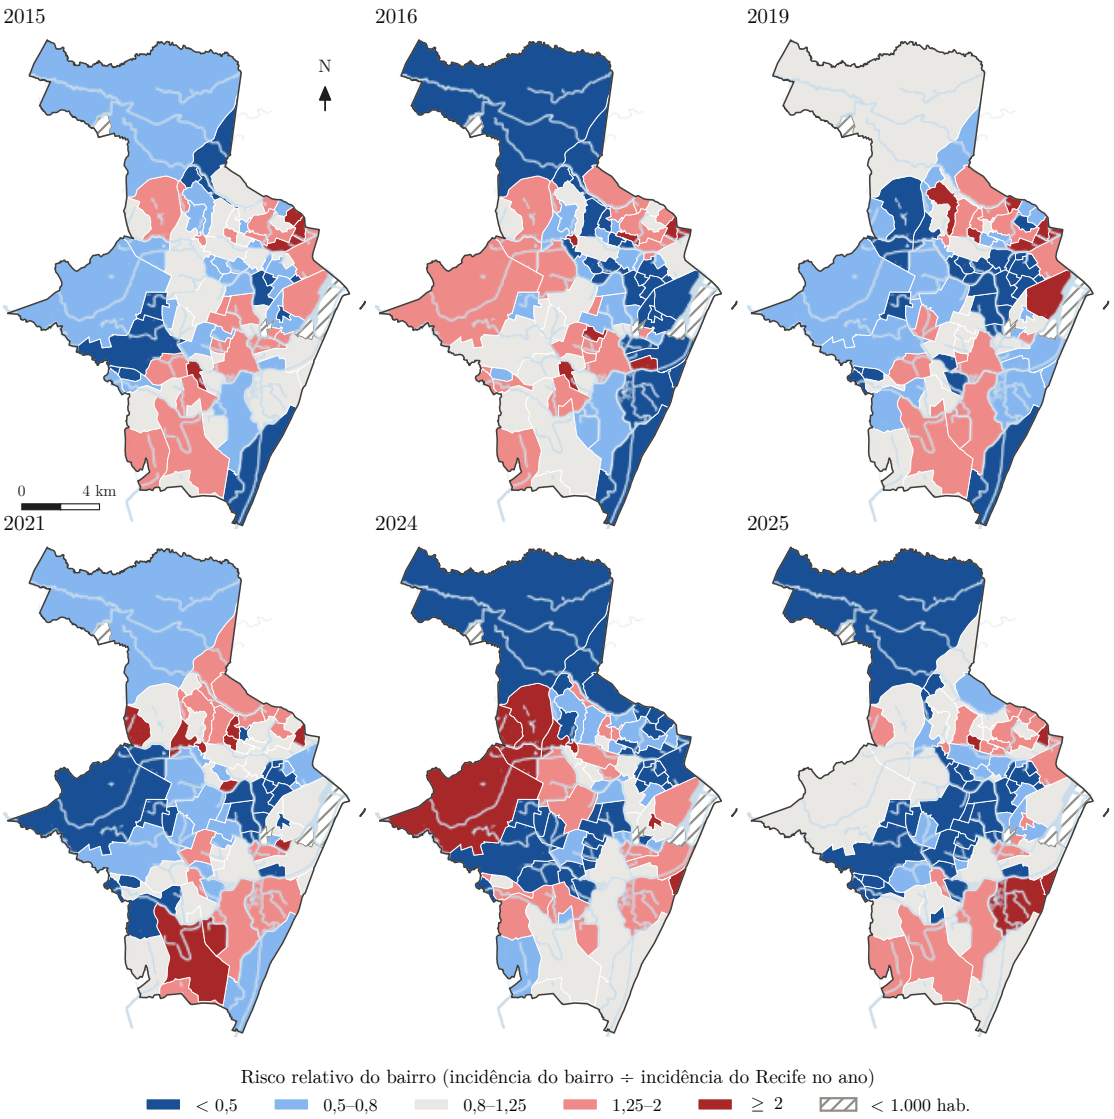


Figura 6: Risco relativo de dengue por bairro nos seis anos com mais casos (todos os anos na Figura 14): incidência do bairro (casos confirmados por habitante, Censo 2022) dividida pela incidência do Recife no mesmo ano. Vermelho: risco acima da média da cidade; azul: abaixo. Bairros com menos de 1.000 habitantes (hachurados) foram omitidos por instabilidade da taxa.

mas é moderada: a distribuição espacial de um ano explica apenas parcialmente a do seguinte, o que justifica uma ferramenta de detecção recorrente em vez de mapas de risco estáticos.

Tabela 4: Persistência espacial entre anos consecutivos.

	Spearman				
Anos	Células 500 m	Incidência bairro	Jaccard top 10%	Células top 10% (%)	Casos seguintes no top 10% (%)
2013–2014	0,37	0,38	0,23	12,4	32,2
2014–2015	0,38	−0,17	0,11	12,2	18,8
2015–2016	0,79	0,54	0,29	10,2	25,2
2016–2017	0,45	0,26	0,27	10,2	26,5
2017–2018	0,46	0,45	0,24	16,9	33,5
2018–2019	0,58	0,44	0,20	13,7	28,0
2019–2020	0,53	0,33	0,18	11,2	23,7
2020–2021	0,51	0,38	0,24	12,9	26,3
2021–2022	0,59	0,40	0,23	10,3	24,9
2022–2023	0,46	0,38	0,30	12,4	30,8
2023–2024	0,51	0,49	0,19	10,8	21,9
2024–2025	0,60	0,30	0,20	11,3	23,4
Média	0,52	0,35	0,22	12,0	26,2

Células: contagem de casos por célula de 500 m. Incidência bairro: casos por habitante nos bairros com pelo menos 1.000 moradores. Top 10%: células no decil superior de casos do ano anterior (empates incluídos).

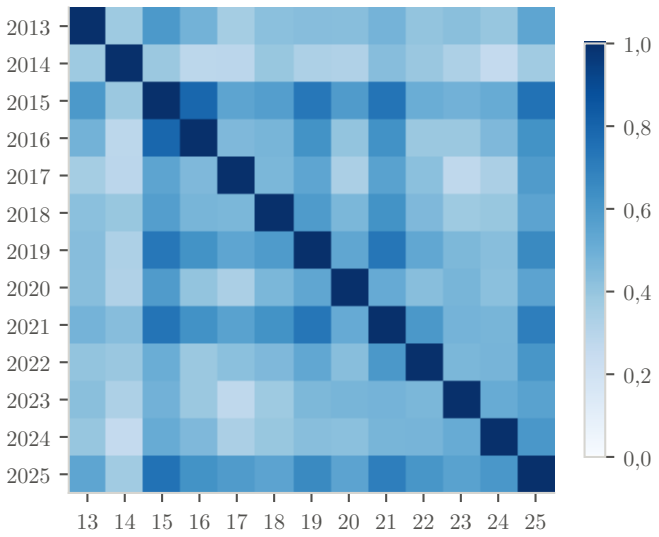


Figura 7: Mapa de calor da correlação de Spearman entre anos dos casos por célula de 500 m.

2.3 Sensibilidade aos parâmetros

Foram avaliadas 154 janelas não sobrepostas de 4 semanas com pelo menos 30 casos (67 de baixa, 59 de média e 28 de alta incidência). O comportamento do DBSCAN depende fortemente do nível de incidência (Tabela 5 e Figura 8). Com `min_samples` = 10, no máximo 4% das janelas de baixa incidência produziram algum cluster com $\varepsilon \leq 0{,}5$ km; com `min_samples` = 3 e $\varepsilon = 0{,}3$ km, 73%. Nas janelas de alta incidência, a mesma configuração $\varepsilon = 0{,}3$ km e `min_samples` = 3 gera uma mediana de 60 clusters e classifica só 20% dos casos como ruído. Ou seja, parâmetros fixos adequados a períodos epidêmicos silenciam o software em períodos interepidêmicos, e vice-versa. A silhueta diminui com o aumento de ε (de 0,95 a 0,48 com `min_samples` = 3), refletindo a fusão de agregados vizinhos em clusters maiores e menos compactos.

Tabela 5: Sensibilidade do DBSCAN aos parâmetros, por nível de incidência da janela de 4 semanas (mediana [IIQ]).

eps (km)	min_samples	Nº de clusters	Ruído (%)	Janelas c/ cluster (%)
Incidência baixa (<100); 67 janelas				
0,20	3	1 [0–2]	95 [90–100]	61
0,20	5	0 [0–0]	100 [100–100]	12
0,20	10	0 [0–0]	100 [100–100]	3
0,30	3	2 [0–3]	90 [82–100]	73
0,30	5	0 [0–0]	100 [100–100]	21
0,30	10	0 [0–0]	100 [100–100]	3
0,50	3	5 [2–6]	71 [61–85]	91
0,50	5	1 [0–1]	93 [86–100]	57
0,50	10	0 [0–0]	100 [100–100]	4
0,75	3	6 [4–8]	49 [42–59]	99
0,75	5	2 [1–3]	76 [64–90]	79
0,75	10	0 [0–0]	100 [100–100]	15
Incidência média (100–400); 59 janelas				
0,20	3	6 [3–16]	81 [71–90]	100
0,20	5	2 [0–4]	94 [86–100]	71
0,20	10	0 [0–0]	100 [98–100]	25
0,30	3	12 [6–23]	67 [52–76]	100
0,30	5	2 [1–6]	87 [77–95]	88
0,30	10	0 [0–1]	100 [91–100]	41
0,50	3	17 [12–24]	42 [25–50]	100
0,50	5	6 [4–14]	67 [46–76]	98
0,50	10	1 [0–2]	89 [80–100]	63
0,75	3	14 [12–16]	19 [10–27]	100
0,75	5	8 [6–10]	37 [21–54]	100
0,75	10	2 [1–6]	75 [52–91]	85
Incidência alta (>400); 28 janelas				
0,20	3	82 [42–150]	37 [20–50]	100
0,20	5	33 [18–81]	56 [34–74]	100
0,20	10	9 [2–28]	78 [64–94]	86
0,30	3	60 [43–79]	20 [8–30]	100
0,30	5	38 [22–52]	37 [17–54]	100
0,30	10	12 [5–34]	61 [34–82]	96
0,50	3	28 [21–33]	5 [2–11]	100
0,50	5	18 [16–21]	13 [3–21]	100
0,50	10	11 [9–14]	31 [13–51]	100
0,75	3	9 [5–13]	1 [0–3]	100
0,75	5	7 [4–11]	3 [1–7]	100
0,75	10	7 [5–9]	10 [2–23]	100

Janelas de 4 semanas não sobrepostas com ao menos 30 casos geocodificados no nível de rua. IIQ: intervalo interquartil.

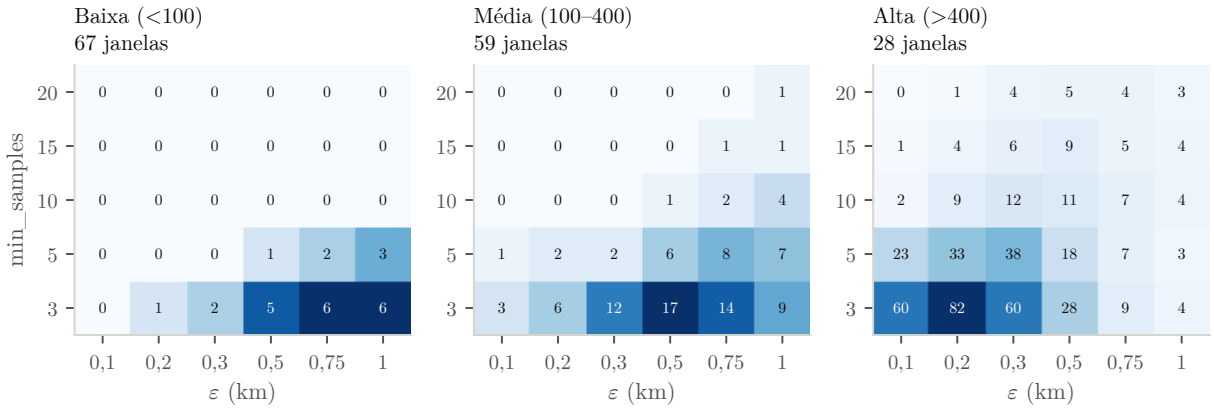


Figura 8: Mapas de calor do número mediano de clusters por janela de 4 semanas na grade de parâmetros, por nível de incidência.

2.4 Estabilidade dos agrupamentos

As soluções foram estáveis a perturbações de ±10% em ε (ARI mediano de 0,79 a 0,91) e à remoção aleatória de 10% dos casos (ARI de 0,91 a 0,93) em todas as configurações (Tabela 6). A estabilidade a `min_samples` ±1 é alta para `min_samples` = 10 (0,91–0,94), mas cai para 0,50–0,82 quando `min_samples` = 3. Nesse caso a perturbação representa uma variação relativa de 33%, e com `min_samples` = 2 qualquer par de casos próximos forma um cluster. Em resumo, as áreas detectadas não dependem de um ajuste fino dos parâmetros nem de casos individuais.

Tabela 6: Estabilidade dos agrupamentos: ARI mediano entre a solução de referência e a solução perturbada.

eps (km)	min_samples	Janelas	eps ×0,9	eps ×1,1	min_samples −1	min_samples +1	Subamostra 90%
0,20	3	128	0,90	0,89	0,50	0,65	0,93
0,20	5	78	0,88	0,91	0,78	0,76	0,91
0,20	10	41	0,88	0,90	0,93	0,91	0,92
0,30	3	136	0,89	0,88	0,52	0,65	0,92
0,30	5	94	0,87	0,89	0,79	0,81	0,92
0,30	10	53	0,86	0,88	0,93	0,93	0,93
0,50	3	148	0,86	0,86	0,61	0,68	0,92
0,50	5	124	0,83	0,86	0,79	0,77	0,92
0,50	10	68	0,84	0,80	0,91	0,94	0,93
0,75	3	153	0,83	0,86	0,82	0,79	0,93
0,75	5	140	0,80	0,88	0,80	0,80	0,92
0,75	10	88	0,79	0,87	0,93	0,94	0,93

ARI: índice de Rand ajustado (1 = partições idênticas). Perturbações de parâmetros calculadas com `stability_analysis` do DengueSphere; subamostra: 10 réplicas por janela, ARI sobre os casos retidos. Excluídas as janelas sem cluster na referência, em que o ARI seria 1 trivialmente.

2.5 Validação prospectiva

Foram avaliadas 593 janelas semanais (308 no treino e 285 no teste). Na grade de parâmetros (Tabela 7 e Figura 9) há um compromisso claro entre concentração e cobertura. Configurações restritivas ($\varepsilon = 0{,}2$ km, `min_samples` = 10) atingem PAI mediano de 9,8 no teste, mas só emitem alerta em 22% das janelas. Configurações permissivas ($\varepsilon = 0{,}75$ km, `min_samples` = 3) capturam 61% dos casos futuros, porém com PAI de 2,3. Pelo critério definido no treino (maior PAI entre as configurações com alerta em $\geq 80\%$ das janelas), foi selecionada a configuração $\varepsilon = 0{,}3$ km e `min_samples` = 3.

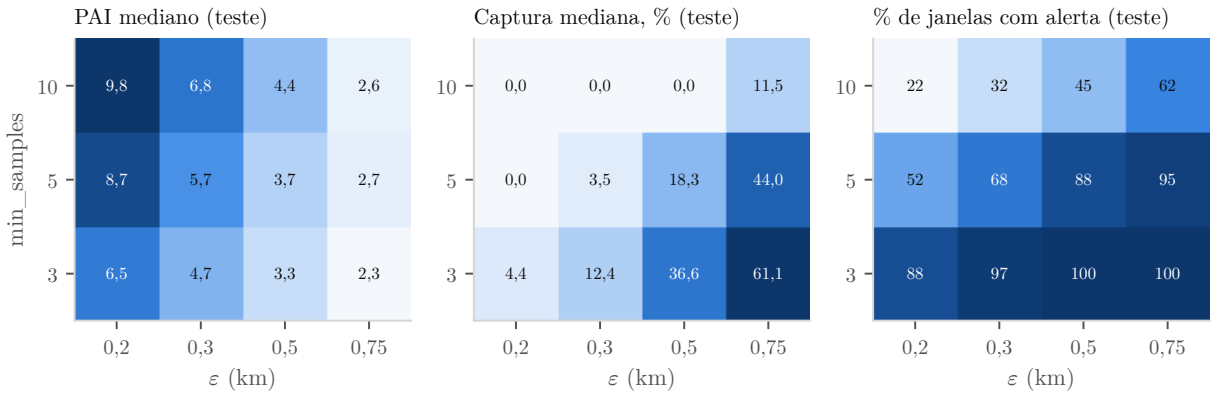


Figura 9: Mapas de calor do desempenho prospectivo do DBSCAN no período de teste (2020–2025): PAI mediano (janelas com alerta), captura mediana dos casos das 4 semanas seguintes e proporção de janelas com ao menos um cluster.

Tabela 7: Desempenho prospectivo do DBSCAN na grade de parâmetros (medianas por janela). Em negrito, a configuração escolhida no treino.

		Treino (2013–2019)				Teste (2020–2025)				
eps	min_s.	Alerta %	Capt. %	Área %	PAI	Alerta %	Capt. %	Área %	PAI	PAI_{pop}
0,20	3	77	4,9	0,33	6,76	88	4,4	0,43	6,53	2,64
0,20	5	53	0,0	0,10	7,74	52	0,0	0,08	8,75	3,20
0,20	10	35	0,0	0,00	6,94	22	0,0	0,00	9,76	3,31
0,30	**3**	**85**	**12,3**	**1,31**	**4,86**	**97**	**12,4**	**1,74**	**4,73**	**2,14**
0,30	5	62	3,1	0,31	5,59	68	3,5	0,43	5,73	2,47
0,30	10	39	0,0	0,00	5,20	32	0,0	0,00	6,81	2,81
0,50	3	94	31,1	6,45	3,13	100	36,6	8,75	3,29	1,66
0,50	5	78	14,6	2,18	3,64	88	18,3	3,15	3,71	1,79
0,50	10	46	0,0	0,00	3,78	45	0,0	0,00	4,40	2,29
0,75	3	99	54,6	20,45	2,38	100	61,1	24,02	2,33	1,36
0,75	5	88	37,6	10,02	2,66	95	44,0	13,92	2,67	1,52
0,75	10	58	10,6	2,31	2,65	62	11,5	2,46	2,56	1,54

Alerta: % de janelas em que o DBSCAN encontrou ao menos um cluster. Captura: % dos casos das 4 semanas seguintes dentro da área sinalizada (zero quando não há alerta). Área: % da área do município (219,3 km^2). PAI = Captura/Área e PAI_{pop} = Captura/% da população, calculados apenas nas janelas com alerta. Critério de escolha: maior PAI mediano no treino entre as configurações com alerta em ≥80% das janelas.

Com essa configuração, no período de teste, as áreas sinalizadas pelo DengueSphere ocuparam em mediana 1,8% do município e capturaram 13,3% dos casos das 4 semanas seguintes: PAI mediano de 4,73 (IIQ 3,54–7,97), quase cinco vezes o esperado ao acaso (Tabela 8 e Figura 10). O desempenho no teste foi equivalente ao do treino (PAI 4,86), sem sinal de sobreajuste.

Parte dessa concentração, porém, decorre da densidade demográfica: as células mais populosas da cidade, escolhidas sem nenhuma informação sobre casos e com a mesma área, já alcançam PAI de 3,22. O PAI populacional isola esse efeito. As áreas sinalizadas pelo DBSCAN abrigavam 4,1% da população e receberam 13,3% dos casos seguintes, um risco por habitante 2,14 vezes maior que a média do Recife (IIQ 1,58–3,42; treino 2,13). Para as células mais populosas, esse valor foi de 0,70: as áreas mais densas da cidade têm *menos* casos por habitante que a média. O DBSCAN superou essa referência populacional em 96,8% das janelas de teste ($\Delta\text{PAI}_{\text{pop}}$ +1,41; $p < 0{,}001$), o que mostra que o software identifica risco além do que a distribuição da população explica (Tabela 9).

Na comparação com as demais referências, os dois PAIs contam histórias complementares. Por área, o DBSCAN superou o ranking de bairros por incidência em 91,3% das janelas (ΔPAI +2,40) e o *buffer* de todos os casos em 88,8% (+1,49), ambos com $p < 0{,}001$. Por habitante, a vantagem sobre o *buffer* se mantém (83,8% das janelas; +0,55), mas o ranking de bairros por incidência alcança risco por habitante equivalente (PAI_{pop} 2,13 contra 2,14; $p = 0{,}29$). Ou seja, priorizar bairros inteiros pela incidência atinge a mesma proporção de casos por morador visitado, mas exige cobrir quase o dobro da área (3,3% contra 1,8% do município). A KDE de mesma área foi ligeiramente superior ao DBSCAN nas duas métricas (ΔPAI −0,36; $\Delta\text{PAI}_{\text{pop}}$ −0,10).

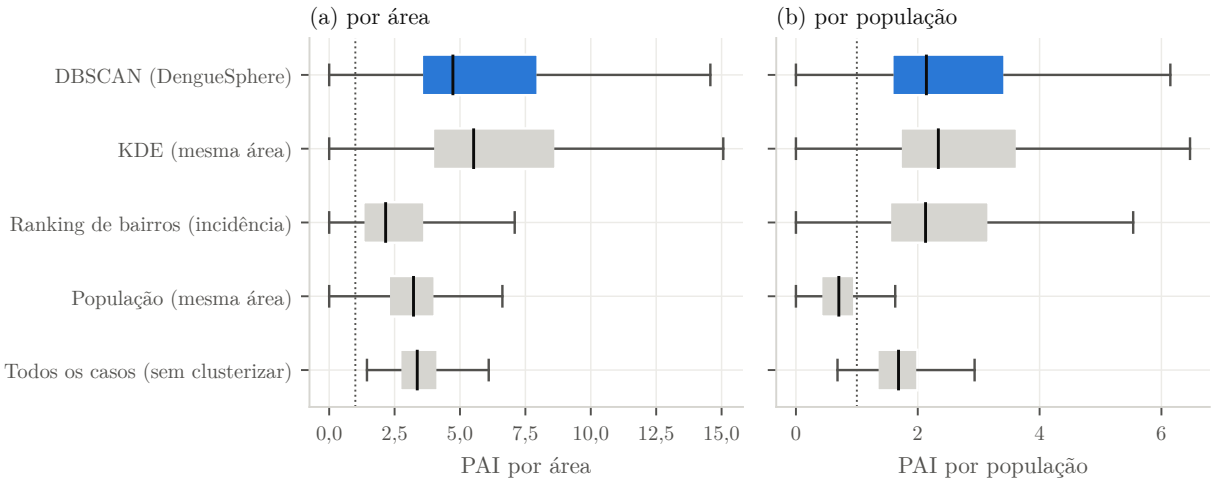


Figura 10: Distribuição, por janela do período de teste (2020–2025), do PAI por área (a) e por população (b) na previsão dos casos das 4 semanas seguintes ($\varepsilon = 0{,}3$ km, `min_samples` = 3). A linha pontilhada (valor 1) corresponde, em (a), à seleção aleatória de áreas e, em (b), ao risco médio por habitante da cidade.

A captura acompanha a dinâmica epidêmica (Figura 11): ultrapassa 90% no pico de 2015, quando os clusters cobrem grande parte da área urbana, e fica abaixo de 10% em períodos interepidêmicos, quando a transmissão é dispersa. A Figura 12 ilustra uma janela de 2015 com os parâmetros do estrato de alta incidência. Os 73 clusters detectados delimitam 17,1% do município, onde ocorreram 58% dos casos das quatro semanas seguintes.

A estratificação por incidência (Tabela 10) dá parâmetros práticos. Em baixa incidência, $\varepsilon = 0{,}5$ km e `min_samples` = 3 emitiram alerta em 99% das janelas de teste, com PAI de 4,72 (praticamente igual ao da KDE, 4,85) e risco por habitante 2,21 vezes a média. Em alta incidência, $\varepsilon = 0{,}2$ km e `min_samples` = 10 produziram áreas compactas (0,4% do município) com PAI de 6,15 e PAI_{pop} de 2,34. No estrato intermediário, a configuração escolhida no treino ($\varepsilon = 0{,}2$ km, `min_samples` = 5) teve a taxa de alerta reduzida de 80% para 62% no teste, sinal de que esse estrato demanda parâmetros menos restritivos.

Tabela 8: Validação prospectiva: DBSCAN (ε = 0,3 km, min_samples = 3) e métodos de referência na previsão dos casos das 4 semanas seguintes (medianas por janela com alerta).

	Treino		Teste (2020–2025)				
Método	PAI	PAI_{pop}	Capt. %	Área %	Pop. %	PAI [IIQ]	PAI_{pop} [IIQ]
DBSCAN (DengueSphere)	4,86	2,13	13,3	1,77	4,11	4,73 [3,54–7,97]	2,14 [1,58–3,42]
KDE (mesma área)	5,38	2,32	15,7	1,77	4,25	5,52 [3,97–8,65]	2,34 [1,72–3,63]
Ranking de bairros (incidência)	2,53	1,82	9,7	3,28	3,63	2,16 [1,31–3,64]	2,13 [1,54–3,16]
População (mesma área)	3,04	0,81	6,6	1,77	9,86	3,22 [2,28–4,03]	0,70 [0,41–0,96]
Todos os casos (sem clusterizar)	3,20	1,54	45,0	11,85	24,20	3,37 [2,72–4,14]	1,68 [1,34–1,99]

PAI = captura/% da área; PAI_{pop} = captura/% da população residente (Censo 2022) na área sinalizada. KDE: células com maior densidade kernel ($\sigma = \varepsilon$) até a mesma área do DBSCAN. Ranking de bairros: bairros inteiros por incidência (casos/habitante) na janela até atingir a área do DBSCAN. População: células mais populosas, com a mesma área do DBSCAN, sem informação de casos. Todos os casos: buffer de raio ε em torno de todos os casos da janela, sem clusterização.

Tabela 9: Comparação pareada, janela a janela, do DBSCAN com cada método de referência (teste de Wilcoxon).

Métrica	Período	Referência	Janelas	DBSCAN melhor (%)	Δ mediano	p
PAI	Treino	KDE (mesma área)	262	22,5	−0,11	<0,001
		Ranking de bairros (incidência)	262	83,2	1,32	<0,001
		População (mesma área)	262	67,6	1,24	<0,001
		Todos os casos (sem clusterizar)	262	88,2	1,65	<0,001
	Teste	KDE (mesma área)	277	18,8	−0,36	<0,001
		Ranking de bairros (incidência)	277	91,3	2,40	<0,001
		População (mesma área)	277	72,6	1,34	<0,001
		Todos os casos (sem clusterizar)	277	88,8	1,49	<0,001
PAI_{pop}	Treino	KDE (mesma área)	262	26,7	−0,07	<0,001
		Ranking de bairros (incidência)	262	44,3	0,00	0,176
		População (mesma área)	262	90,5	1,31	<0,001
		Todos os casos (sem clusterizar)	262	84,7	0,58	<0,001
	Teste	KDE (mesma área)	277	28,2	−0,10	<0,001
		Ranking de bairros (incidência)	277	45,1	−0,07	0,286
		População (mesma área)	277	96,8	1,41	<0,001
		Todos os casos (sem clusterizar)	277	83,8	0,55	<0,001

Δ = métrica do DBSCAN − métrica da referência, por janela; valores positivos favorecem o DBSCAN. As janelas semanais se sobrepõem (3 das 4 semanas), de modo que os valores de p são aproximados.

Tabela 10: Parâmetros escolhidos no treino para cada nível de incidência e seu desempenho no teste.

Incidência (casos/4 sem.)	ε	min_s.	Alerta treino %	Alerta teste %	PAI treino	PAI teste	PAI KDE teste	PAI_{pop} teste	Área teste %
Baixa (<100)	0,5	3	88	99	4,06	4,72	4,85	2,21	3,49
Média (100–400)	0,2	5	80	62	12,00	12,78	16,47	4,59	0,13
Alta (>400)	0,2	10	94	85	4,74	6,15	8,19	2,34	0,43

Mesmo critério de escolha da Tabela 7, aplicado dentro de cada estrato.

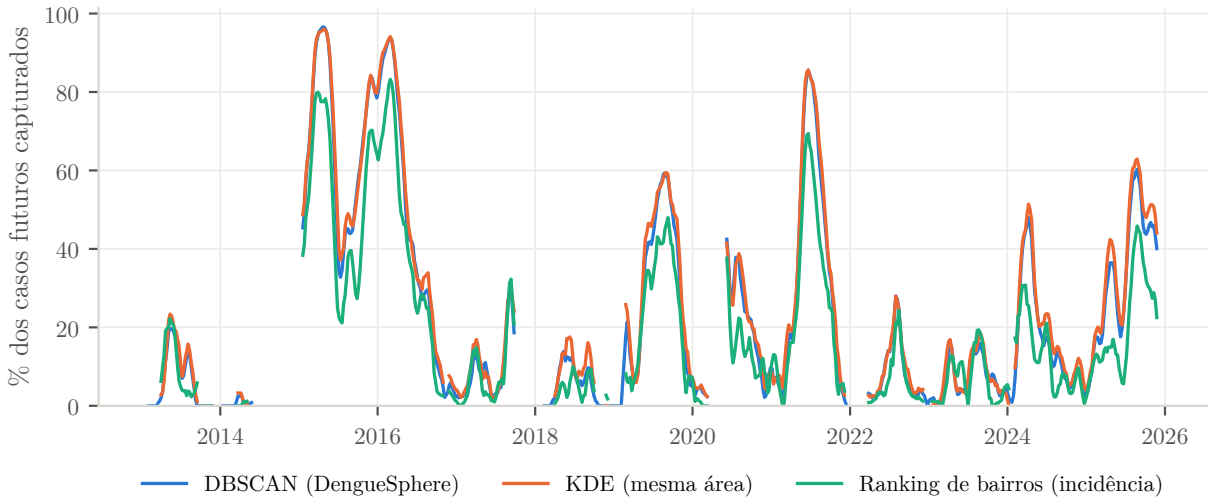


Figura 11: Captura dos casos das 4 semanas seguintes ao longo do tempo (média móvel de 4 semanas; interrupções indicam semanas sem casos suficientes).

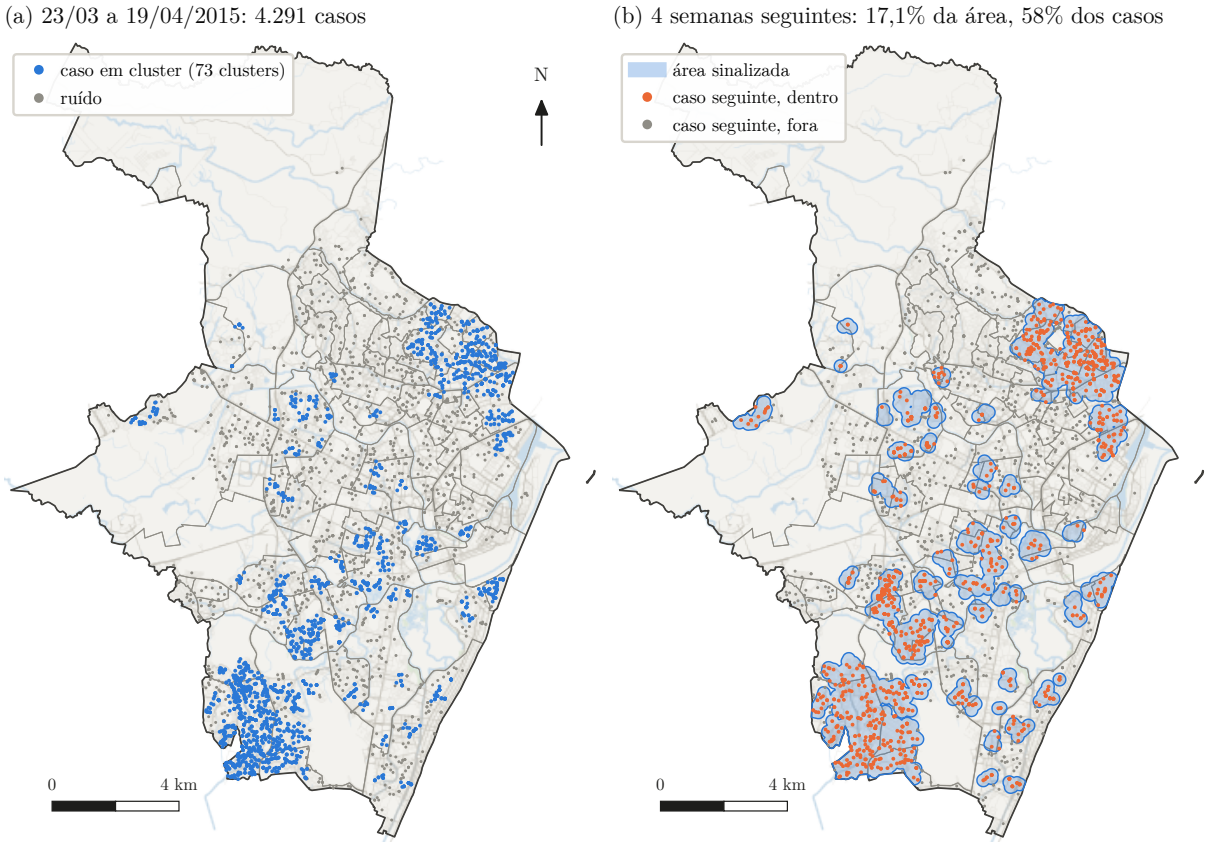


Figura 12: Exemplo de uso do DengueSphere no pico de 2015, com os parâmetros do estrato de alta incidência ($\varepsilon = 0{,}2$ km, `min_samples` $= 10$). (a) Casos das quatro semanas analisadas: em azul, os atribuídos a algum cluster; em cinza, os classificados como ruído. (b) Área sinalizada (união dos círculos de raio ε em torno dos casos em cluster) e casos ocorridos nas quatro semanas seguintes.

Os resultados se mantiveram quando a análise usou todas as notificações não descartadas, que é o que a vigilância dispõe em tempo real (PAI 4,64 contra 4,79 e PAI_{pop} 2,05 contra 2,14 na análise principal; Tabela 11). Incluir os casos localizados apenas pelo centroide do bairro elevou o PAI para 5,33. Esse ganho, porém, é em parte artificial: casos empilhados no mesmo ponto formam clusters densos.

Tabela 11: Análise de sensibilidade da validação prospectiva (2013–2025, configuração principal; medianas nas janelas com alerta).

				DBSCAN		PAI_{pop} das referências		
Variante	Janelas	Alerta %	Capt. %	PAI	PAI_{pop}	KDE	Bairros	População
Principal: confirmados, nível de rua	593	91	15,1	4,79	2,14	2,33	2,00	0,75
Não descartados (tempo real), nível de rua	595	91	15,1	4,64	2,05	2,26	1,90	0,78
Confirmados, incluindo centroides de bairro	606	95	17,6	5,33	2,41	2,68	2,17	0,78

Não descartados: confirmados, inconclusivos e sem classificação final — o conjunto disponível à vigilância antes do encerramento das investigações. Com centroides de bairro, casos empilhados no mesmo ponto formam clusters artificiais, o que infla a captura.

2.6 Desempenho computacional

A clusterização do DengueSphere processou 40.000 casos em 0,35 s ($\varepsilon = 0{,}3$ km) e 0,50 s ($\varepsilon = 0{,}5$ km), com crescimento moderadamente superlinear no número de casos (40 vezes mais casos, cerca de 115 vezes mais tempo) (Tabela 12). Isso é mais que o maior volume semanal observado (1.573 casos) e que o total do ano de 2015 (23.576). Varreduras de parâmetros como as deste estudo são, portanto, viáveis em tempo interativo.

Tabela 12: Tempo de execução da clusterização do DengueSphere (mediana de 3 execuções).

Casos	eps = 0,3 km (ms)	eps = 0,5 km (ms)
1.000	3	4
2.500	9	12
5.000	21	26
10.000	55	71
20.000	139	192
40.000	350	499

`executar_clusterizacao` (DBSCAN, métrica haversine, *ball tree*), min_samples = 10; Apple M2, 16 GB, Python 3.11, scikit-learn.

3 Discussão

Aplicado ao histórico de 13 anos do Recife, o DengueSphere sinaliza áreas que concentram os casos das semanas seguintes cerca de cinco vezes mais do que o acaso por unidade de área e duas vezes mais do que a média por habitante. O desempenho foi estável entre treino e teste, robusto a perturbações dos parâmetros e dos dados e mantido com as notificações disponíveis em tempo real. O ajuste pela população do Censo 2022 é essencial para essa leitura. Sem ele, seria possível atribuir ao software um mérito que é apenas da densidade demográfica; com ele, fica claro que as áreas detectadas têm risco por habitante acima da média, enquanto as áreas simplesmente mais populosas têm risco abaixo dela.

A comparação com o ranking de bairros por incidência mostra onde está o ganho do DBSCAN. Por habitante, as duas estratégias se equivalem; por área, o DBSCAN concentra o mesmo rendimento em cerca de metade do território. Como as ações de controle vetorial (visitas domiciliares, eliminação

de criadouros, bloqueio de transmissão) são planejadas por território e quarteirão, delimitar agregados de algumas centenas de metros em vez de bairros inteiros reduz o esforço de campo para um mesmo número de casos alcançados.

A KDE de mesma área obteve desempenho ligeiramente superior (diferença mediana de 0,36 no PAI e de 0,10 no PAI_{pop}). Essa diferença deve ser lida à luz das funções distintas dos dois métodos. A KDE produz uma superfície contínua que exige a escolha externa de um limiar de área. O DBSCAN decide por si quantos agregados existem e quais casos são isolados, e entrega unidades discretas, enumeráveis e com contagem de casos, mais diretamente convertíveis em ordens de serviço para as equipes de campo. A comparação mostra que esse ganho operacional custa pouca precisão preditiva, e o resultado sugere incorporar ao software uma camada de densidade kernel complementar.

O achado com maior implicação prática é a dependência dos parâmetros em relação ao nível de incidência. Valores fixos de `min_samples` adequados a epidemias tornam o software mudo em períodos interepidêmicos, justamente quando a detecção precoce de agregados é mais útil. As configurações da Tabela 10 podem servir como valores padrão adaptativos, selecionados automaticamente pelo número de casos da janela.

Limitações. (i) A geocodificação usa uma base local do OpenStreetMap, e não o serviço Nominatim do software. A concordância de 56 m (mediana) indica que isso não altera as conclusões em escala de bairro, mas logradouros ausentes do OSM, sobretudo em áreas de ocupação informal, foram localizados pelo bairro e excluídos da análise principal (17,1% dos casos). (ii) Cerca de 90% das confirmações foram por critério clínico-epidemiológico (Tabela 13), e o segundo pico de 2015–2016 coincide com a epidemia de Zika no Recife, o que sugere alguma má classificação entre arboviroses. (iii) A população do Censo 2022 foi usada para todos os anos e distribuída dentro de cada setor censitário de modo uniforme (ponderação areal), o que ignora mudanças demográficas intercensitárias e a distribuição interna das moradias. Além disso, a proporção de casos geocodificados no nível de rua pode ser menor em áreas de ocupação informal, o que subestimaria a incidência justamente nas áreas mais vulneráveis. (iv) Faltam dados de agosto a dezembro de 2014. (v) A validação mede concentração espacial de casos futuros, e não o efeito de intervenções, que só poderá ser avaliado com o uso operacional do software.

A Material suplementar

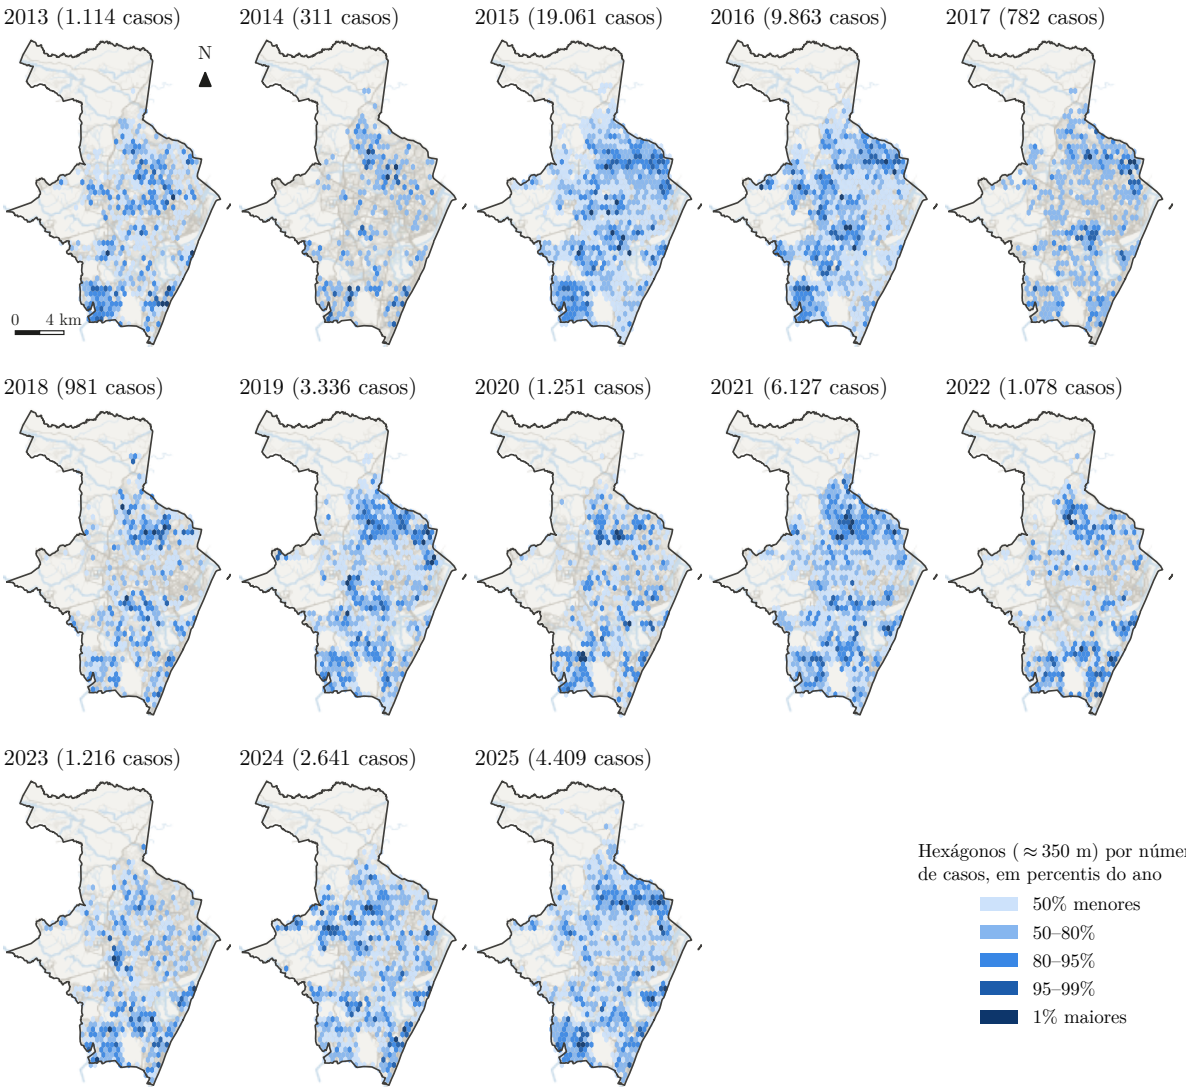


Figura 13: Mapas de calor da distribuição dos casos confirmados em todos os anos do estudo (mesma construção da Figura 4). Em 2014 há dados apenas até julho.

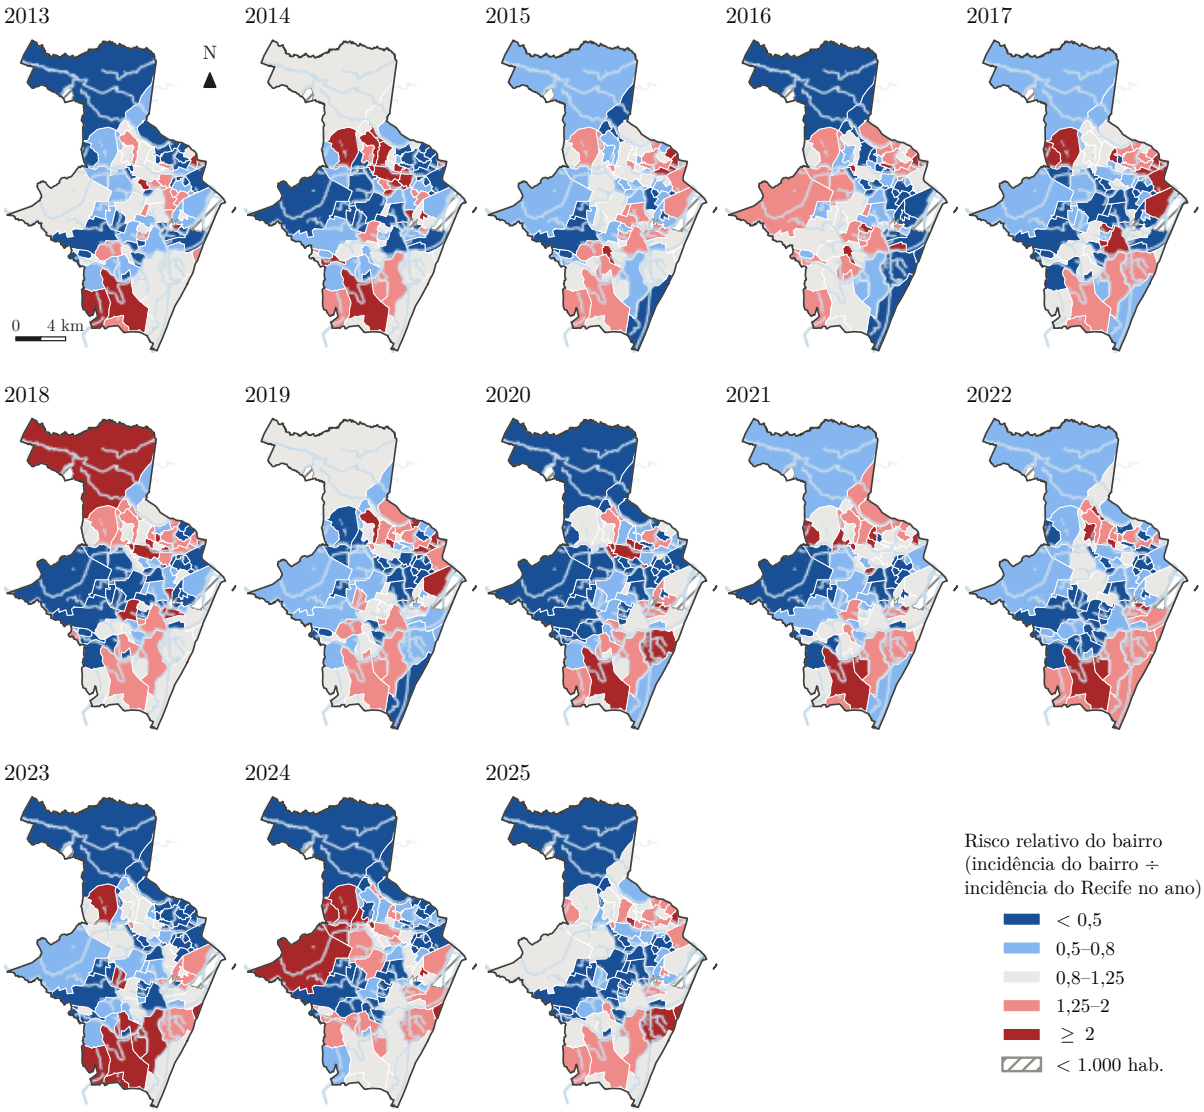


Figura 14: Risco relativo de dengue por bairro em todos os anos do estudo (mesma construção da Figura 6). Em anos de baixa incidência, bairros pouco populosos e extensos, como Guabiraba, alternam entre classes extremas por instabilidade da taxa.

Tabela 13: Classificação final das notificações e critério de confirmação dos casos confirmados, por ano.

Ano	Confirmados	Descartados	Inconclusivos	Sem classif.	Laboratorial (%)	Clínico-epid. (%)
2013	1.304	1.958	0	0	11,9	88,1
2014	363	796	0	0	20,4	79,6
2015	23.576	7.913	3.178	8	7,3	92,1
2016	12.083	4.884	1.515	23	2,0	95,3
2017	955	1.486	4	0	6,7	93,3
2018	1.207	1.466	13	0	15,2	84,8
2019	4.102	2.606	601	0	10,6	89,4
2020	1.544	1.952	122	1	7,2	90,7
2021	7.435	3.541	1	0	6,3	93,7
2022	1.291	1.503	1	0	7,6	92,4
2023	1.414	2.004	83	1	2,5	96,7
2024	3.007	7.231	119	126	3,2	78,1
2025	5.066	3.452	286	247	16,6	73,8

Confirmados: códigos 1–4 (classificação até 2014: dengue clássico, com complicações, FHD, SCD) e 10–12 (classificação de 2014: dengue, com sinais de alarme, grave).